

BÉNIN GEO-WATCH

Système de Surveillance et de Prévision Géopolitique



MÉMOIRE TECHNIQUE ET ANALYTIQUE

Big Data GDELT, Clustering KMeans, Forecasting RandomForest & RAG Pipeline

Auteurs (Équipe G10) :

Ahamadah Marie Cynthia

Data Analyst

OLOUKPONA Bedel

Data Science

ADISSO Nelxie

ML Engineer

Nolhan-Nathan Luzolo ADOHO

ML Engineer

Expertises

Data Engineering

AI / NLP / RAG

Time Series Analysis

UX/UI Design

Table des matières

1	Introduction et Vision Stratégique	2
2	Le Pipeline Data Engineering : Maîtriser le Big Data	2
2.1	Extraction et Filtrage Sémantique	3
2.2	Indice de Stabilité G10 : Une Innovation de Normalisation	3
2.3	Cartographie Granulaire	3
3	Intelligence Artificielle et Modélisation Prédictive	3
3.1	Clustering KMeans : La Segmentation Automatisée	4
3.2	Forecasting avec Random Forest	4
3.2.1	Ingénierie des Caractéristiques (Lag Features)	4
3.2.2	Pourquoi pas le Deep Learning ?	4
4	Architecture RAG : L'Assistant IA Géopolitique	4
4.1	La Puissance de Mistral AI	5
4.2	Le Pipeline de Connaissance	5
5	Dashboarding : L'Interface Homme-Machine	5
5.1	Design Système et Expérience Utilisateur	6
5.2	Le Simulateur "What-If"	6
6	Difficultés, Solutions et Collaboration	6
6.1	Défis Techniques et "War Stories"	7
6.1.1	Le Piège du Formatage : Le Drame de la Virgule Décimale	7
6.1.2	L'Imbroglie des Colonnes : Ambiguïté du Dataset	7
6.1.3	Le Goulot d'Étranglement du RAG : Tensions sur la RAM	7
6.1.4	Le Paradoxe du Voisin : Filtrage du "Bruit" Nigérian	7
6.2	Performance et Déploiement Cloud	7
6.3	Sécurité des Données	8
7	Conclusion et Perspectives de Souveraineté	8

1 Introduction et Vision Stratégique

La stabilité d'une nation repose sur sa capacité à traiter l'information avant qu'elle ne devienne une crise. Dans le cadre du Hackathon iSHEERO 2026, l'Équipe G10 a conçu **Bénin Geo-Watch**, une plateforme d'intelligence augmentée dédiée à la surveillance géopolitique du Bénin.

Notre vision dépasse la simple visualisation de données. Nous avons voulu créer un outil capable de "comprendre" le contexte international, de prédire les ondes de choc diplomatiques et d'offrir un assistant conversationnel capable d'extraire la substance de milliers d'articles de presse. Ce rapport détaille comment nous avons transformé le Big Data de GDELT en un outil de décision stratégique, en surmontant des défis techniques majeurs liés au volume, à la latence et à l'interopérabilité des modèles.

2 Le Pipeline Data Engineering : Maîtriser le Big Data

2.1 Extraction et Filtrage Sémantique

La base GDELT (*Global Database of Events, Language and Tone*) est une source gargantuesque. Pour ce projet, nous avons dû extraire plus de 6 000 événements spécifiques au Bénin sur la période 2025-2026. Le défi principal a été le nettoyage : GDELT utilise des algorithmes automatisés qui génèrent parfois du bruit (événements dupliqués, acteurs mal identifiés). Nous avons mis en place un pipeline de déduplication et de validation des acteurs pour garantir que chaque ligne de notre dataset `events_clean.csv` soit factuelle.

2.2 Indice de Stabilité G10 : Une Innovation de Normalisation

Les échelles de Goldstein (-10 à +10) sont difficiles à interpréter pour un décideur non-expert. Nous avons donc créé un **Indice de Stabilité Composite** normalisé de 0 à 100.

Logique Algorithmique

Le score est calculé par une pondération entre l'impact théorique de l'événement (60% GoldsteinScale) et la perception médiatique associée (40% AvgTone).

$$\text{Indice} = \left(\frac{\text{Goldstein} + 10}{20} \times 0.6 + \frac{\text{Tone} + 10}{20} \times 0.4 \right) \times 100$$

Ce lissage permet d'identifier les périodes de "Calme Diplomatique" (> 50) et les "Zones de Tension" (< 40).

2.3 Cartographie Granulaire

Pour la première fois, nous avons mappé ces scores sur les 12 départements du Bénin. Cela permet de voir, par exemple, que si le Littoral est stable, l'Alibori ou l'Atacora peuvent présenter des micro-tensions spécifiques liées aux enjeux frontaliers.

3 Intelligence Artificielle et Modélisation Prédictive

3.1 Clustering KMeans : La Segmentation Automatisée

Plutôt que de définir nous-mêmes ce qu'est une "crise", nous avons laissé l'IA découvrir les structures de données. Le modèle KMeans a identifié 4 clusters majeurs :

- **Cluster 0 (Crise Aiguë)** : Goldstein moyen de **-3.22**, Tone de **-5.54**. Ce sont les événements de violence ou de rupture diplomatique.
- **Cluster 2 (Diplomatie de Routine)** : Goldstein de **+2.78**, Tone positif. Ce sont les accords et rencontres bilatérales.

3.2 Forecasting avec Random Forest

Le défi du forecasting temporel était de capturer la "mémoire" des tensions.

3.2.1 Ingénierie des Caractéristiques (Lag Features)

Nous avons créé 7 variables de décalage (lag_1 à lag_7) représentant la stabilité des 7 jours précédents. Le modèle **Random Forest Regressor** utilise ces données pour prédire la courbe des 7 jours futurs. Contrairement aux modèles linéaires, il est capable de détecter les ruptures brutales de tendance, cruciales dans le domaine sécuritaire.

3.2.2 Pourquoi pas le Deep Learning ?

Nous avons testé des approches LSTM, mais sur un dataset de 6 000 lignes, le Random Forest s'est révélé plus robuste, moins sujet au sur-apprentissage (*overfitting*) et beaucoup plus rapide à entraîner, permettant une mise à jour quotidienne du dashboard.

4 Architecture RAG : L'Assistant IA Géopolitique

L'innovation phare de l'Équipe G10 est l'assistant conversationnel basé sur la technologie **RAG** (*Retrieval-Augmented Generation*).

4.1 La Puissance de Mistral AI

Nous avons choisi le modèle `mistral-small-latest`. Ce choix repose sur la performance du modèle en langue française et sa capacité à traiter des contextes diplomatiques complexes sans halluciner.

4.2 Le Pipeline de Connaissance

Le système traite plus de 6 000 articles de presse internationale.

1. **Chunking** : Découpage des articles en blocs sémantiques avec un *overlap* de 10% pour ne pas perdre le fil conducteur.
2. **Embeddings** : Utilisation de `mistral-embed` (vecteurs de dimension 1024) pour stocker la "signification" des textes.
3. **FAISS (Vector Store)** : Nous utilisons un index FAISS pour récupérer instantanément les 2 articles les plus pertinents par rapport à la question de l'utilisateur.

Sécurité et Précision

L'IA n'invente rien. Si la réponse n'est pas dans nos 6 000 articles, elle a pour consigne de répondre "Je ne dispose pas de l'information dans ma base GDELT". C'est une garantie de fiabilité pour le jury.

5 Dashboarding : L'Interface Homme-Machine

Le dashboard est le point de convergence de tous nos modèles.

5.1 Design Système et Expérience Utilisateur

Nous avons opté pour un **Dark Mode Premium**. Au-delà de l'esthétique, cela permet une lecture haute performance des indicateurs de couleur (Vert/Rouge). Chaque graphique a été pensé pour répondre à une question précise du décideur : "Où se situent les tensions?", "Qui sont nos partenaires?", "Quelle est la tendance pour demain?".

5.2 Le Simulateur "What-If"

C'est la fonctionnalité préférée de nos testeurs. Elle permet d'ajuster des sliders (Échelle de Goldstein, Tone, Volume) pour simuler un scénario. L'IA (le modèle KMeans) classe alors ce scénario en temps réel et dit à l'analyste : "Attention, ce scénario correspondrait à un Cluster de Crise". C'est un outil d'entraînement et d'aide à la décision unique.

6 Difficultés, Solutions et Collaboration

6.1 Défis Techniques et "War Stories"

6.1.1 Le Piège du Formatage : Le Drame de la Virgule Décimale

L'un des obstacles les plus chronophages a été invisible au premier abord : le séparateur décimal. Les données GDELT extraites via certains outils locaux étaient formatées selon le standard français (utilisation de la virgule , au lieu du point .).

Conséquence : Lors de l'ingestion par *Pandas*, des colonnes critiques comme **GoldsteinScale** ou **AvgTone** étaient interprétées comme des types **object** (chaînes de caractères) au lieu de **float**. Cela a bloqué les calculs statistiques et le clustering pendant plusieurs heures de débogage intense avant que l'équipe n'identifie cette subtilité de "locale". La résolution a nécessité un nettoyage systématique via des fonctions de remplacement (`.str.replace(',', ' ')`) avant la conversion forcée des types.

6.1.2 L'Imbroglia des Colonnes : Ambiguïté du Dataset

Un défi analytique majeur est apparu lors de la phase de visualisation : le dataset contenait deux colonnes aux noms similaires, **stability_score** et **score**. L'équipe a d'abord utilisé la première, avant de réaliser que les valeurs étaient incohérentes avec l'échelle normalisée attendue (0-100). Après une analyse approfondie des scripts de nettoyage, nous avons découvert que le véritable indice composite final était stocké dans **score**. Ce type d'ambiguïté, fréquent en Data Science, a nécessité une ré-implémentation complète des fonctions de calcul de KPIs pour garantir la véracité des insights présentés.

6.1.3 Le Goulot d'Étranglement du RAG : Tensions sur la RAM

Lors du déploiement sur *Streamlit Community Cloud*, nous avons été confrontés à des *Timeouts* et des erreurs de mémoire. Calculer les embeddings pour 6 353 articles à chaque démarrage de l'application était impossible avec les ressources limitées du cloud. **Solution** : Nous avons dû concevoir un système de pré-calcul en local, exportant l'index vectoriel **FAISS** sous forme de fichier binaire. L'application charge désormais l'index en moins de 500ms, transformant une attente de plusieurs minutes en une interaction instantanée.

6.1.4 Le Paradoxe du Voisin : Filtrage du "Bruit" Nigérian

Le Nigeria, de par son poids géopolitique, sature souvent les flux GDELT liés au Bénin. Nous avons remarqué que les crises nigérianes faisaient artificiellement chuter l'indice de stabilité béninois. L'équipe a dû affiner les requêtes de filtrage pour s'assurer que seuls les événements impliquant directement le Bénin ou ayant un impact frontalier avéré soient comptabilisés, évitant ainsi une "pollution" des données nationales par les tensions des pays limitrophes.

6.2 Performance et Déploiement Cloud

La taille du dataset et des index vectoriels imposait une gestion fine de la RAM. Nous avons optimisé les types de données (float32 vs float64) et utilisé le gestionnaire **uv** pour garantir des déploiements rapides et reproductibles sur Streamlit Cloud.

6.3 Sécurité des Données

Nous avons implémenté une gestion stricte des secrets via `st.secrets`. Les clés API Mistral ne sont jamais présentes dans le code source, garantissant la sécurité du dépôt GitHub de l'équipe.

7 Conclusion et Perspectives de Souveraineté

Bénin Geo-Watch est plus qu'un projet étudiant ; c'est un prototype de **Souveraineté Numérique**. En maîtrisant le pipeline de la donnée brute à l'intelligence conversationnelle, l'Équipe G10 montre que le Bénin peut se doter d'outils de pointe pour protéger sa stabilité.

Les prochaines étapes incluent l'intégration de sources de données locales (Presse béninoise, réseaux sociaux) et le raffinement du modèle de forecasting avec des variables économiques (taux de change, prix des matières premières) pour une vision encore plus holistique.